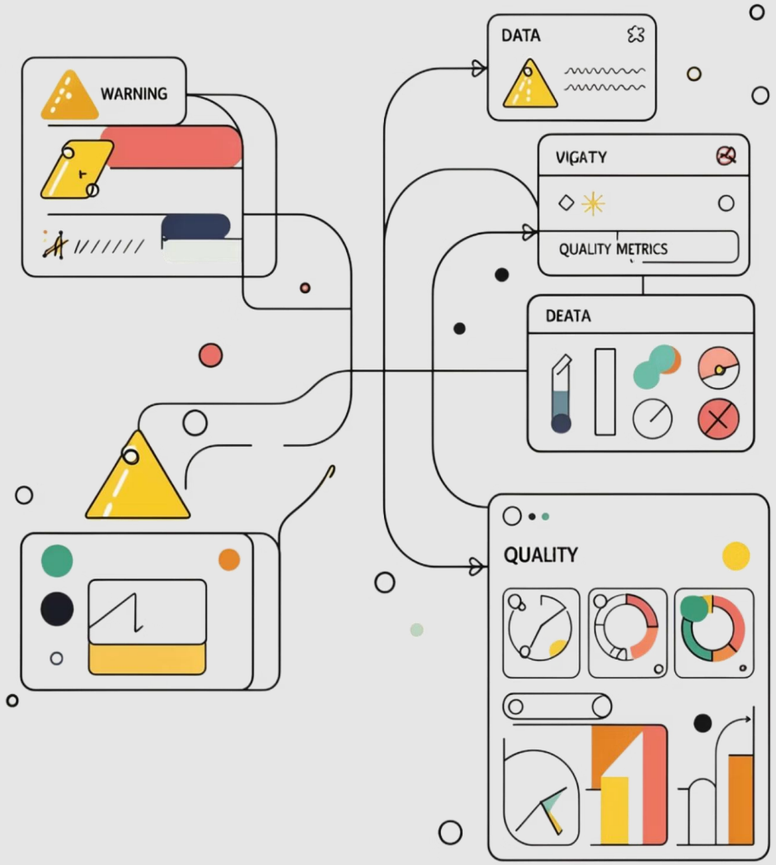

¿Cómo detectar problemas en mis datos antes de que sea tarde?

Saber que la calidad existe no es suficiente. Hay que **medirla de forma sistemática y automática**, especialmente cuando los datos llegan continuamente de distintas fuentes.

DATA QUALITY · ETL · PYTHON

Made with GAMMA

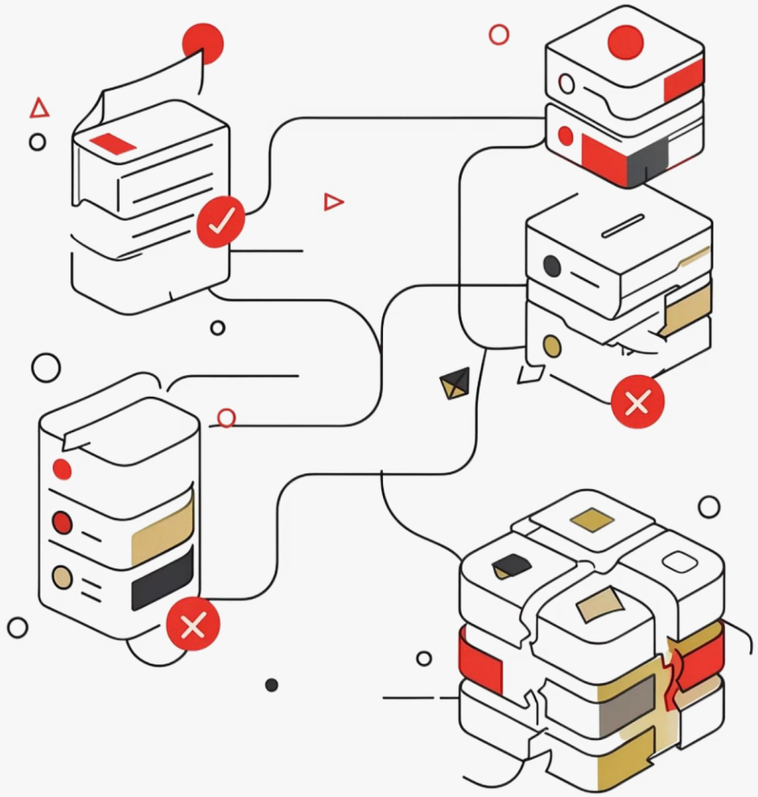

El problema: los datos llegan rotos y nadie lo ve

Cuando un pipeline ingiere datos de múltiples fuentes sin ningún control, los errores se acumulan en silencio. Un **valor nulo inesperado**, un **duplicado** o un **rango fuera de límites** pueden invalidar análisis enteros antes de que alguien lo detecte.

🔴 Sin visibilidad

No sabes qué calidad tienen tus datos hasta que algo falla

⏱️ Detección tardía

El error se descubre en producción, no en ingesta: conviene bloquear el error antes de que entre

💸 Coste elevado

Corregir datos ya procesados es mucho más caro que prevenirlo

Made with GAMMA

Las métricas que todo analista debe conocer

% de Nulos

Proporción de celdas vacías por columna. Indica datos incompletos o fallos en la ingesta.

% de Duplicados

Registros repetidos que inflan conteos y distorsionan agregaciones.

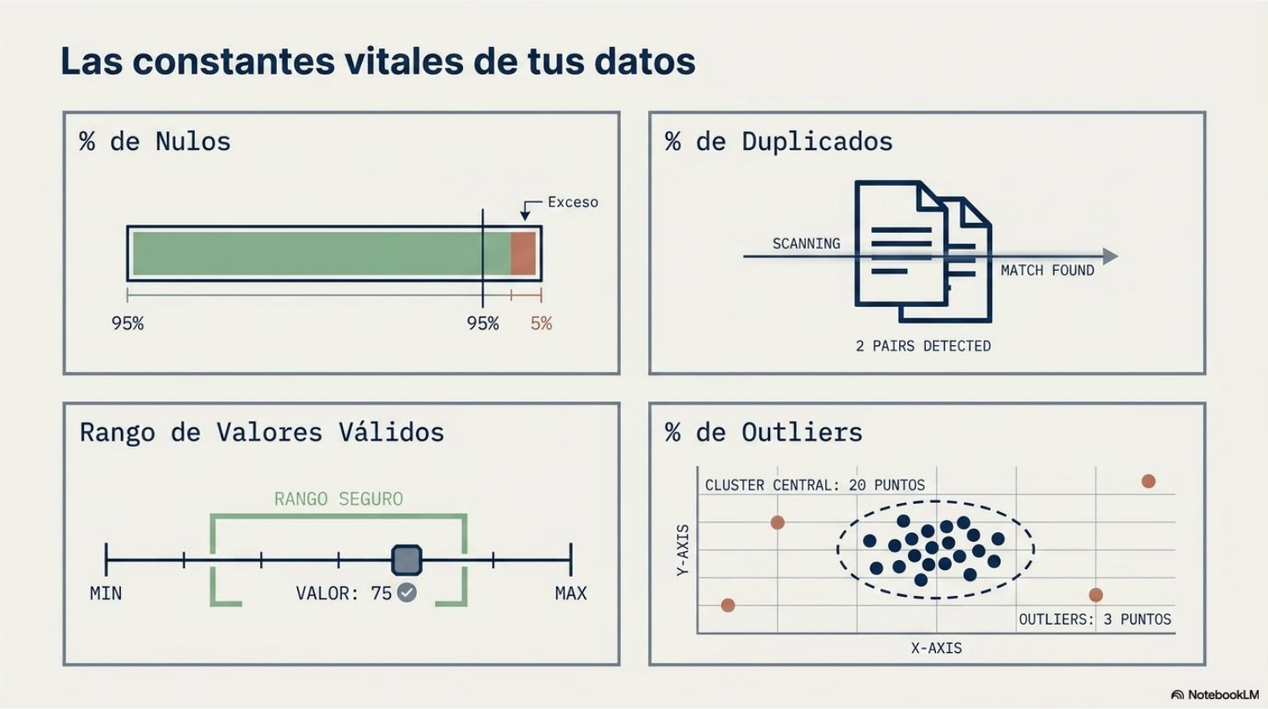

Rango de valores válidos

Comprobar que los valores están dentro de un dominio esperado (ej. edad entre 0 y 120).

% de Outliers

Valores atípicos que se desvían significativamente de la distribución normal de la variable.

Made with GAMMA

¿Qué es un "Data Quality Check"?

Un **data quality check** es una validación automática que se ejecuta sobre un conjunto de datos para verificar que cumple unas reglas definidas. A diferencia de una revisión manual puntual, estos checks se integran directamente en el pipeline y se ejecutan **en cada carga de datos**.

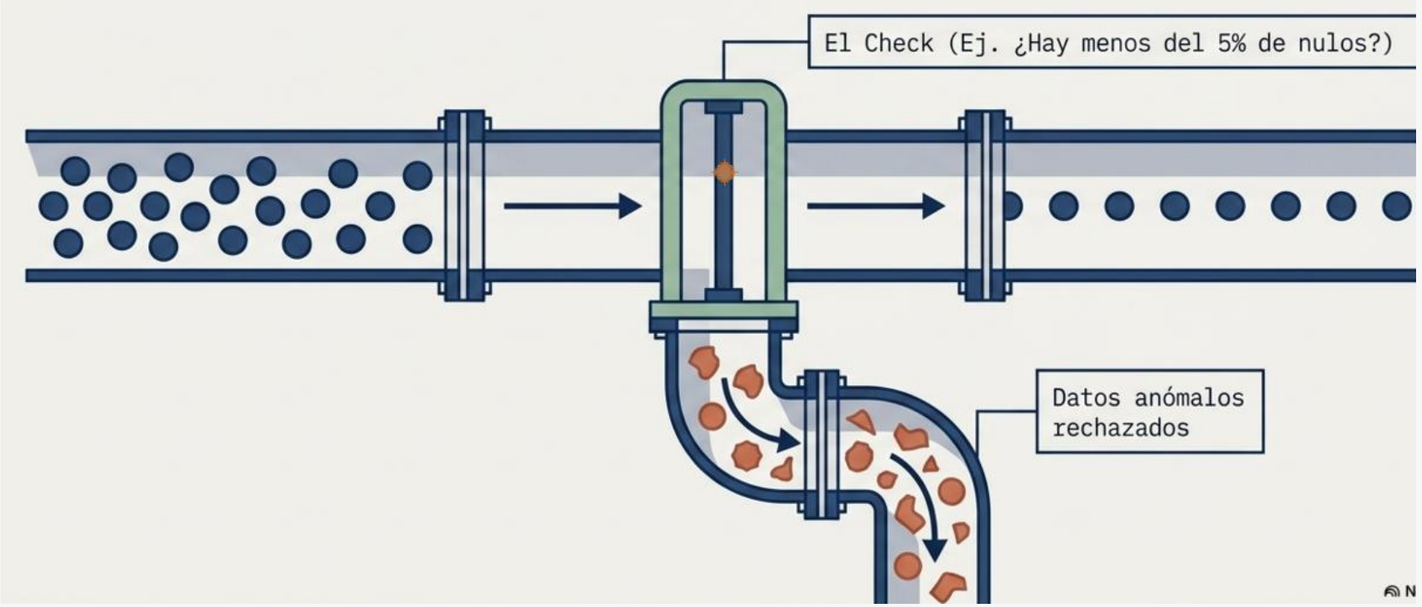

Definir la regla

Ej: "la columna `email` no puede tener nulos"

Ejecutar automáticamente

Se lanza en cada ejecución del pipeline, sin intervención humana

Alertar o bloquear

Si falla, notifica al equipo o detiene el pipeline antes de propagar el error

Made with GAMMA

Detección manual vs. automática: la diferencia es crítica

🔧 Detección manual (una vez)

- Un analista revisa los datos tras un fallo

Se usa `.info()` o Excel de forma puntual

- El error ya impactó en los resultados
- Depende de la disponibilidad de una persona
- No escala con el volumen de datos

⚙️ Detección automática (siempre)

- El check se ejecuta en cada ingesta automáticamente
- Se integra en el pipeline ETL como un paso más
- El error se captura antes de propagarse
- Funciona 24/7 sin intervención humana
- Escalable a cientos de tablas y fuentes

ⓘ La automatización no elimina la revisión humana, pero la desplaza al momento correcto: cuando hay algo que realmente requiere atención.

Made with GAMMA

Demo: los checks básicos ya existen en Pandas

Antes de usar herramientas avanzadas, Pandas ofrece tres métodos que ya son un **primer nivel de control de calidad** en cualquier exploración de datos.

1

`.info()`

Muestra tipos de dato, nombre de columnas y **número de valores no nulos** por columna. Detecta columnas con tipos incorrectos o muchos nulos de un vistazo.

2

`.describe()`

Estadísticas descriptivas (media, mínimo, máximo, cuartiles). Permite identificar **valores fuera de rango** y posibles outliers rápidamente.

3

`.isnull().sum()`

Devuelve el **conteo exacto de nulos** por columna. Es el check más directo para medir completitud de datos.

Made with GAMMA

Ejemplo concreto: un pipeline ETL con checks integrados

Extraer

Leer CSV o base de datos

Transformar

Limpiar, deduplicar y normalizar

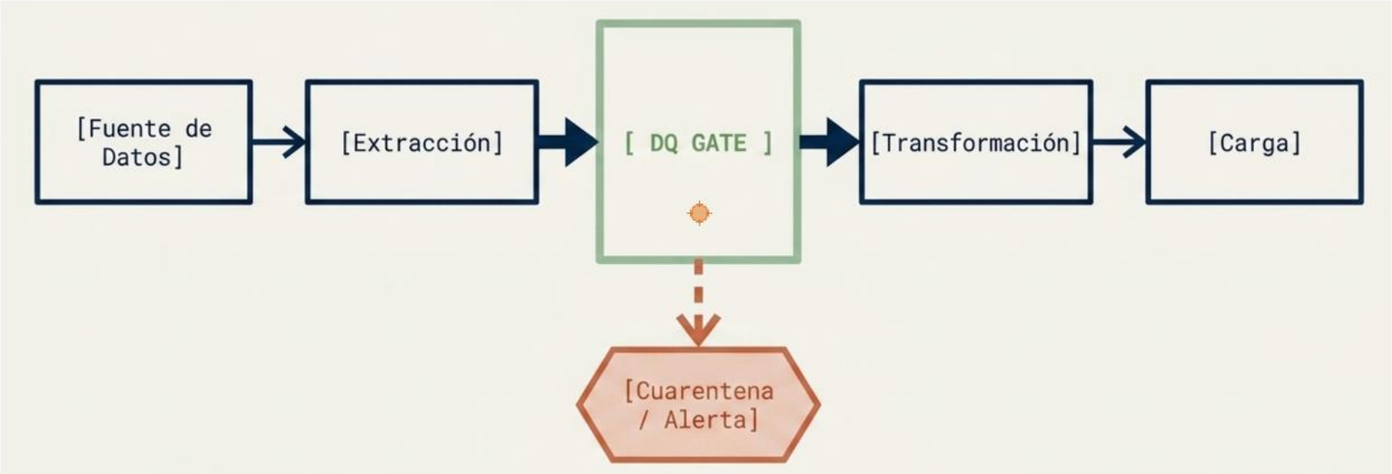

Cargar

Escribir si la validación pasa

Validar

isnull, describe y reglas

El paso de **Validación** actúa como puerta de control: si los datos no superan los checks definidos, el pipeline se detiene y notifica al equipo antes de cargar datos corruptos al almacén.

Made with GAMMA

Herramienta 1: ydata-profiling

ydata-profiling (antes `pandas-profiling`) genera un **informe HTML interactivo** completo sobre la calidad de un DataFrame con una sola línea de código.

¿Qué hace?

Analiza automáticamente nulos, duplicados, distribuciones, correlaciones, valores únicos y outliers.

¿Cómo se usa?

```
from ydata_profiling import ProfileReportprofile = ProfileReport(df)profile.to_file("report.html")
```

¿Cuándo usarlo?

Ideal en fase de exploración inicial y como informe periódico de calidad para stakeholders no técnicos.

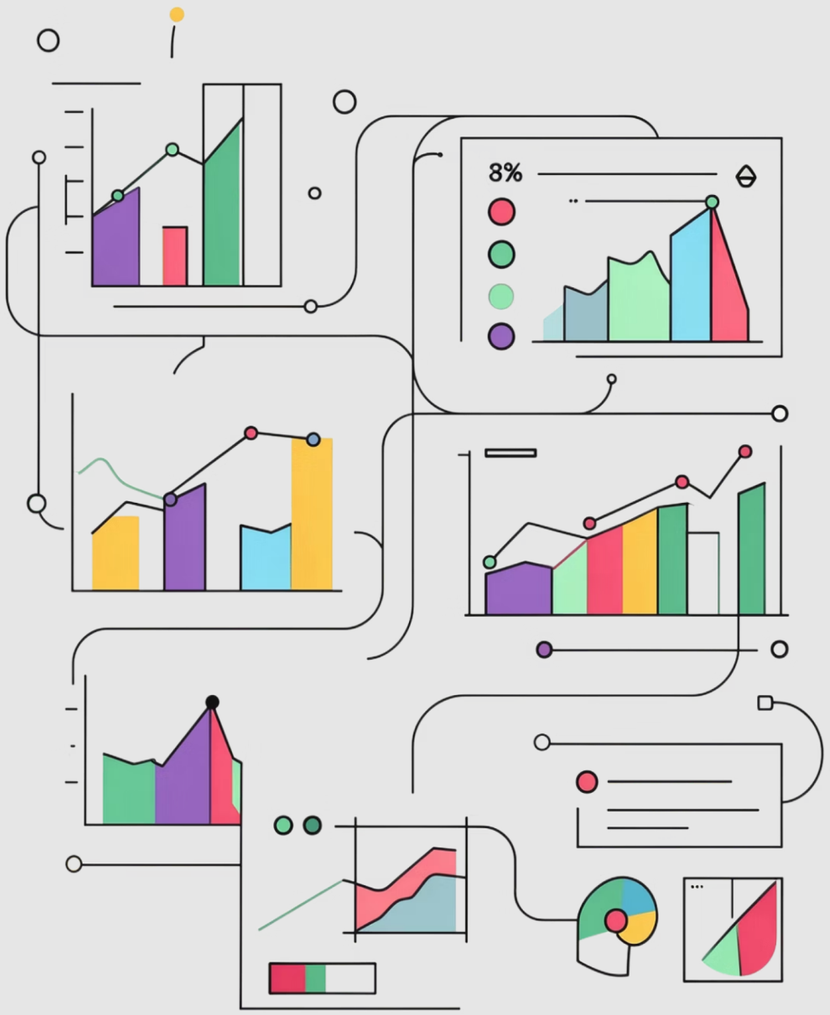

Herramientas avanzadas: Great Expectations y dbt tests

Great Expectations

Permite definir **expectativas** como código (`expect_column_values_to_not_be_null`, `expect_column_values_to_be_between`). Genera documentación automática y se integra con Airflow, Spark y otros orquestadores.

---

dbt tests

Incluye tests nativos (`unique`, `not_null`, `accepted_values`) y permite escribir tests personalizados en SQL. Se ejecutan como parte del pipeline de transformación en el data warehouse.

> Ambas herramientas llevan los checks de calidad a **producción**, no solo al entorno de desarrollo.

Made with GAMMA

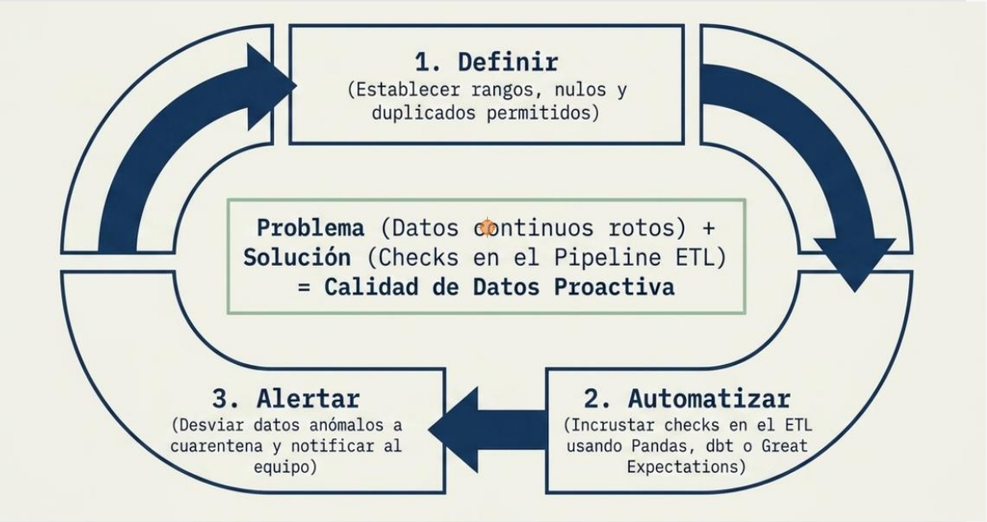

Conclusiones clave

1 **Medir es el primer paso**

Nulos, duplicados, rangos y outliers son las métricas mínimas que todo pipeline debe monitorizar.

2 **Automatizar los checks**

Un check manual puntual no es suficiente. Los checks deben ejecutarse en cada ingesta, de forma automática.

3 **Empezar simple, escalar después**

`.info()`, `.describe()` e `.isnull().sum()` son un punto de partida válido. Luego incorporar ydata-profiling, Great Expectations o dbt tests según la madurez del pipeline.

Made with GAMMA