Documentación de Datos

¿Qué, cómo y para quién?

🧭 ¿Cómo explico este dataset a alguien que no lo ha visto nunca?

🚨 El problema — ¿qué pasa si esto no existe?

Un dataset sin documentación es como un mapa sin leyenda.

Nadie sabe qué significa cada columna, de dónde viene el dato ni en qué confiar.

❌

Errores silenciosos

Se usa salario_neto cuando se necesitaba salario_bruto. Nadie lo detecta.

⏳

Tiempo perdido

Cada analista nuevo hace las mismas preguntas. Todo va por Slack o email.

🔄

Dato duplicado / inconsistente

Tres equipos usan versiones diferentes del mismo dataset sin saberlo.

📋 ¿Qué es un diccionario de datos?

Cada campo del dataset tiene su propia ficha con esta información:

salarios_tech_schema.csv

```csv
nombre_campo,tipo_dato,descripcion,valores_permitidos,ejemplo
id_empleado,Integer,Identificador unico del empleado,Secuencial,1024
salario_anual,Float,Salario bruto en euros,Mayor a 0,45000.00
nivel_seniority,String,Nivel de experiencia profesional,"Junior, Mid, Senior, Lead",Senior
fecha_contratacion,Date,Fecha de incorporacion,Formato ISO 8601 (YYYY-MM-DD),2025-03-15
```

nombre_campo	tipo_dato	descripcion	valores_permitidos	ejemplo
id_empleado	Integer	Identificador unico del empleado	Secuencial	1024
salario_anual	Float	Salario bruto en euros	Mayor a 0	45000.50
nivel_seniority	String	Nivel de experiencia profesional	Junior, Mid, Senior, Lead	Senior
fecha_contratacion	Date	Fecha de incorporacion	Formato ISO 8601 (YYYY-MM-DD)	2025-03-15

💡 *Ejemplo real con el dataset salarios_tech de la semana pasada*

🔍 Documentar el dato vs. documentar el proceso

📄 Documentar el DATO

¿Qué significa cada campo?

- Nombre, tipo y descripción de cada columna
- Valores válidos, nulos permitidos, rango esperado
- Quién es el dueño del dato (Data Owner)
- Ejemplo de valor real

⚙️ Documentar el PROCESO

¿De dónde viene y cómo se genera?

- Pipeline o script que genera el dataset
- Frecuencia de actualización y fuente de origen
- Transformaciones aplicadas (limpieza, agregación)
- Dependencias con otros datasets

Ambas documentaciones son necesarias — y ambas se quedan obsoletas si nadie las mantiene.

⚠️ La documentación se queda obsoleta — ¿cómo evitarlo?

1

📝

Docs cerca del código

Markdown en el mismo repo. Si cambia el pipeline, cambia la doc en el mismo PR.

2

🔗

Vincular al origen

La doc apunta a la fuente real: tabla en BD, script en GitHub, API endpoint.

3

👤

Asignar propietario

Cada dataset tiene un Data Owner responsable de mantener su ficha actualizada.

4

🔔

Revisar en ciclos

Revisión periódica (mensual/trimestral) como parte del workflow del equipo.

🛠️ *Herramientas: Markdown en GitHub · Confluence · Notion · Comentarios en notebooks | Formato mínimo: columna / tipo / descripción / ejemplo*

✅ En resumen

🗺️ Sin documentación, el dataset es un mapa sin leyenda

📋 El diccionario de datos es el estándar mínimo: campo · tipo · descripción · ejemplo

🔄 Documenta tanto el dato como el proceso que lo genera

👥 La documentación es responsabilidad de todo el equipo, no solo del ingeniero

📌 Para que no quede obsoleta: asigna propietario, ponla cerca del código, revísala en ciclos

¿Preguntas?