



Somos
F5

¿Las máquinas pueden ser injustas?

Introducción a los sesgos en la Inteligencia Artificial

ABRIMOS RUTAS **INCLUSIVAS**
AL TALENTO DIGITAL



Bloque I: ¿Qué es un sesgo?	• ¿Qué es y por qué importa?
Bloque II: Tipos de sesgos	• Tipos de sesgos • ¿De dónde vienen estos sesgos?
Bloque III: ¿Cómo evitarlos?	• ¿Cómo podemos evitarlos? • Tríada CID





Grupo I:

¿Qué es un sesgo? e Importancia dentro de la IA y mundo de los datos



¿Qué es un sesgo?



¿QUÉ ES UN SESGO? EN ANÁLISIS DE DATOS

Definición de sesgo

Un sesgo es un error sistemático en el proceso de recolección, tratamiento o análisis de datos que hace que los resultados se desvien de la realidad de forma constante en una dirección determinada. No es un error por azar (ruido), sino un error con dirección fija que se repite siempre.

"Garbage in, garbage out" - La calidad de tus conclusiones depende de la calidad de tus datos.



Sesgo Algorítmico - Decisiones injustas

Ejemplo: IA que filtra currículums basándose en contrataciones históricas sesgadas hacia hombres, penalizando a mujeres.

Ejemplo visual de sesgo

Cinta métrica estirada que quita 2cm a todas las mediciones (sesgo) vs. error de 1mm por viento (azar).



Sesgo de Selección - Destroza la representatividad

Ejemplo: Encuesta sobre tecnología en España 2026 hecha solo por Twitter/X. La gente mayor y sin redes sociales queda fuera.



Sesgo de Confirmación - Conclusiones falsas

El analista selecciona solo los datos que confirman su hipótesis, ignorando evidencia contraria.



Bajo Sesgo + Baja Varianza

Disparos en el centro de la diana. El resultado ideal: conclusiones precisas y consistentes.



Alto Sesgo + Baja Varianza

Disparos agrupados pero lejos del centro. Peligro: conclusiones firmes pero falsas.

¿Por qué importa?

72%

de los sistemas de IA
de RRHH en EE.UU.
usan algoritmos que
pueden discriminar

35%

más errores en
reconocimiento facial
para mujeres de
piel oscura

1 de 3

decisiones judiciales
en algunos países
ya involucran
algoritmos de IA





Grupo II: Casos



Amazon y la IA que penalizaba a las mujeres



El plan

Amazon quería una IA para revisar miles de CVs y seleccionar a los mejores candidatos automáticamente.



El entrenamiento

La IA aprendió de 10 años de CVs de empleados anteriores... que eran mayoritariamente hombres.



El problema

La IA empezó a penalizar CVs que incluían palabras como "mujeres" o nombres de universidades femeninas.



El escándalo

En 2018, Reuters reveló el caso. Amazon abandonó el proyecto. Nunca se usó para tomar decisiones.

El Efecto Espejo



¿Cómo aprendió el sesgo?

El modelo fue entrenado con currículums de contrataciones de Amazon entre **2004 y 2014**. Como los puestos técnicos estaban dominados por hombres, el sistema identificó un patrón simple:

 **Ser hombre era un factor común entre los candidatos exitosos.**



Cómo "Cazaba" el Género

Variables Proxy

Penalizaba la palabra *"Women's"* — como en "Women's Chess Club" o universidades femeninas.

Lenguaje de Género

Premiaba verbos agresivos como *"executed"* o *"captured"*, más frecuentes en perfiles masculinos.

La Decisión Final

El sesgo estaba tan arraigado que Amazon **canceló el proyecto en 2017** ante el riesgo ético y reputacional.

❏ *"La IA no elimina el prejuicio humano — lo automatiza y amplifica a gran escala."*




El reconocimiento facial que no ve igual a todos

La historia:

En 2019, la investigadora Joy Buolamwini (MIT) demostró que los sistemas de reconocimiento facial de IBM, Microsoft y Face++ cometían errores dramáticamente diferentes según género y raza.

Ella misma descubrió el problema cuando el sistema no reconocía su propia cara y tuvo que ponerse una máscara blanca para que funcionara.

¿Cuánto falla?





Caso 2: Reconocimiento Facial y Gender Shades

Joy Buolamwini descubrió que el software de análisis facial **no detectaba su rostro**. Tuvo que ponerse una máscara blanca para ser reconocida. Junto a Timnit Gebru, publicó **Gender Shades (2018)**, evaluando los sistemas de Microsoft, IBM y Face++.



Los Resultados de Gender Shades

0.8%

Error — Hombres piel clara

Prácticamente nulo

34.7%

Error — Mujeres piel oscura

Casi 1 de cada 3 mal clasificadas

46.8%

Error — Fitzpatrick tipo VI

Equivalente a lanzar una moneda

¿Por qué ocurre?

Los datasets de entrenamiento estaban sesgados: **IJB-A** contenía 79.6% piel clara y **Adience** un 86.2% piel clara. Si entrenas con piel clara, aprendes a reconocer piel clara. El resto es "ruido".

La Respuesta de Buolamwini

Creó un nuevo dataset **balanceado por género y tono de piel** para exponer el problema ante la industria y el mundo.



La Reacción de la Industria y la Reauditoría (2020)

Impacto inmediato

Noticia mundial: MIT Tech Review, NYT, BBC. Microsoft prometió mejorar — y lo hizo parcialmente. IBM desarrolló un dataset más diverso.

Gender Shades II (2020)

Microsoft redujo errores, pero **ninguna empresa eliminó el sesgo por completo**. Ninguna publicó desgloses de precisión por subgrupo.

"La rendición de cuentas no es un evento único — es un proceso continuo."

— Joy Buolamwini

El NIST (2019) confirmó y amplió los hallazgos: **189 algoritmos, 99 desarrolladores, 18 millones de imágenes**. Falsos positivos hasta **100x mayores** en personas africanas y asiáticas; **2-5x mayores** en mujeres.



Casos Reales: Arrestos Injustos



Robert Williams — Detroit, 2020


Primer arresto injusto conocido por FR en EE.UU. Arrestado frente a su familia. El jefe de policía admitió: *"96% de las veces se equivoca."* 30 horas detenido. La ACLU demandó — acuerdo en 2024.



Randal Quran Reid — Georgia, 2022

Arrestado por un crimen en Louisiana. **Nunca había estado allí.** El ladrón real pesaba 40 libras más y tenía un lunar que Reid no tenía. Pasó **6 días detenido**. La orden no mencionaba el uso de FR.





Porcha Woodruff — Detroit, 2023

El Caso

Mujer negra, **embarazada de 8 meses**, arrestada por un carjacking. La verdadera autora no estaba embarazada.

La Paradoja

El error era **evidente a simple vista** — pero el arresto ocurrió igualmente.

El Patrón

Tres casos en Detroit. Todos afectando a personas negras. Exactamente lo que Buolamwini advirtió.



Rite Aid y Amazon Rekognition

Rite Aid (FTC, 2023)

Usó FR en cientos de tiendas durante **8 años**. Miles de falsos positivos, con más errores en comunidades negras y asiáticas. Clientes escaneados sin saberlo.

❌ Prohibido usar reconocimiento facial por **5 años**.

Amazon Rekognition — Test de la ACLU

Compararon fotos del Congreso con mugshots: **28 miembros falsamente identificados**. El 40% eran personas de color, que representan solo el 20% del Congreso.

⚠️ Amazon negó el sesgo hasta que la evidencia fue abrumadora.





Conclusiones: El Costo del Sesgo en IA

- La IA amplifica la historia
Sin datos diversos y auditorías rigurosas, los algoritmos automatizan y escalan los prejuicios históricos.
- Las consecuencias son reales
Arrestos injustos, humillaciones públicas y discriminación sistémica — no son errores abstractos.
- La regulación responde
La **Ley de IA de la UE** clasifica los sistemas de contratación y FR como "**Alto Riesgo**", exigiendo supervisión humana estricta.



COMPAS: el algoritmo que decidía quién iba a la cárcel

¿Qué era COMPAS?

Era un software usado en tribunales de EE.UU. para predecir la probabilidad de que una persona reincidiera en un crimen.

Los jueces usaban esta puntuación para decidir si alguien salía en libertad condicional o se quedaba en prisión preventiva.

En 2016, ProPublica analizó 7,000 casos en Florida y publicó sus hallazgos.

Lo que encontraron



Personas negras eran clasificadas como «alto riesgo» el doble de veces que personas blancas, sin historial equivalente.

Personas blancas que sí reincidieron habían recibido puntuaciones bajas de riesgo.



El algoritmo era opaco: nadie podía ver cómo calculaba las puntuaciones.



El Caso COMPAS


"Los algoritmos no son neutrales: pueden heredar los prejuicios humanos"

ÉTICA · INTELIGENCIA ARTIFICIAL · JUSTICIA

Made with **GAMMA**



¿Qué es COMPAS?



COMPAS es un software de IA utilizado en juzgados de Estados Unidos para **predecir la reincidencia** de personas acusadas. A partir de datos personales, el algoritmo asigna una puntuación de **riesgo del 1 al 10**. Los jueces empleaban esa nota para decidir entre libertad bajo fianza o prisión preventiva.

⚠ El mismo historial delictivo.
Dos personas. **Puntuaciones radicalmente distintas** según su raza.

Persona A - Blanca

Mismos antecedentes menores → **Puntuación: 3** (Riesgo Bajo)

Persona B - Negra

Mismos antecedentes menores → **Puntuación: 8** (Riesgo Alto)



¿Por qué falló el algoritmo?

ProPublica demostró que COMPAS se equivocaba **el doble con personas negras**. La causa no era una casilla de "raza" —legalmente prohibida—, sino los datos históricos con los que fue entrenado.

1

La falacia de la objetividad

El modelo usaba datos de arrestos, zona de residencia, ingresos y nivel educativo. Aparentemente neutros, pero profundamente correlacionados con la raza.

2

El reflejo del retrovisor

La policía históricamente patrullaba más los barrios afroamericanos, generando más arrestos por delitos menores. El algoritmo aprendió esa desigualdad como si fuera una verdad objetiva.

3

Sesgo amplificado

El algoritmo no era racista por sí mismo: **automatizó y magnificó** el sesgo sistémico ya existente en la sociedad.



La trampa de la «justicia matemática»

Dos métricas, dos verdades

Northpointe defendía que su algoritmo era **justo en calibración**: un «7» significaba el mismo riesgo estadístico para cualquier persona, independientemente de su raza.

Pero la auditoría reveló una brecha alarmante en las **tasas de error**:

- ❌ Si el algoritmo fallaba con una persona blanca, la dejaba libre. Si fallaba con una persona negra, la mantenía encerrada.

Métrica	Personas blancas	Personas negras
Falsos Positivos (predicho peligroso, no reincide)	~23%	~45%
Falsos Negativos (predicho seguro, sí reincide)	~48%	~28%

El algoritmo era sistemáticamente **«optimista» con los blancos** y **«pesimista» con los negros** cuando cometía errores.



El Teorema de la Imposibilidad

Hay una conclusión matemáticamente demostrada que va más allá del caso COMPAS: cuando dos grupos tienen **tasas de arresto históricas distintas**, es **imposible** que un algoritmo cumpla al mismo tiempo las dos condiciones de equidad.

i No es un fallo técnico que se pueda corregir. Es una limitación matemática fundamental. Elegir entre calibración e igualdad de errores es, en última instancia, una **decisión política y ética**, no estadística.

Lección clave

Los algoritmos no eliminan la injusticia; la codifican. Preguntar «¿es preciso?» no es suficiente: hay que preguntar «¿a quién perjudica cuando falla?»



El debate pendiente

Decidir qué tipo de equidad priorizar no es una tarea técnica. Es una decisión que debe tomar la sociedad, con transparencia y participación democrática.





Grupo III: Origen de los Sesgos



SESGO EN LA IA: DESMONTANDO EL MITO DE LA NEUTRALIDAD ALGORÍTMICA

La inteligencia artificial no es neutra. El sesgo algorítmico refleja prejuicios humanos en datos y diseño, distorsionando resultados y reforzando desigualdades en salud, empleo y justicia. Desafío social, no solo técnico.

¿DÓNDE NACE EL ERROR? EL CICLO DE VIDA DEL SESGO



IMPACTO Y RIESGOS REALES



TIPOS DE SESGOS EN LA IA




6 PASOS PARA UNA IA JUSTA



GOBERNANZA: EL PILAR DE LA CONFIANZA.
La transparencia y el sistema "human-in-the-loop" son esenciales para transformar la IA en una herramienta de progreso equitativo.

¿De dónde vienen los sesgos?



Clave: Los sesgos no los crea la IA — los hereda de nosotros. Por eso la solución no es solo técnica, es también social.



Grupo IV: Tipos de sesgos



INFOGRAFÍA: SESGOS EN DATOS E INTELIGENCIA ARTIFICIAL

GUÍA VISUAL PARA ENTENDER ERRORES SISTEMÁTICOS EN MODELOS INTELIGENTES




1. SESGO DE REPRESENTACIÓN

DEFICIÓN: Los datos de entrenamiento no reflejan la diversidad de la población real.

CAUSA: Muestreo incompleto o falta de acceso tecnológico.

EJEMPLO: Reconocimiento facial con baja precisión para minorías étnicas.



2. SESGO HISTÓRICO

DEFICIÓN: La IA perpetúa prejuicios y desigualdades pasadas arraigadas en la sociedad.

CAUSA: Datos basados en prácticas discriminatorias históricas.

EJEMPLO: Algoritmos de contratación que descartan candidatas femeninas.



3. SESGO ALGORÍTMICO

DEFICIÓN: Introducido por las decisiones de diseño del propio algoritmo.

CAUSA: Optimización de métricas de eficiencia que ignoran la equidad.

EJEMPLO: Priorizar la velocidad de respuesta sobre la precisión equitativa.




4. SESGO SISTÉMICO

DEFICIÓN: Un circuito de retroalimentación donde la IA altera el entorno que la entrena.

CAUSA: "Profecía Autocumplida" al interactuar el sistema con el mundo real.

EJEMPLO: Algoritmos policiales que sobre-vigilan ciertas zonas, validando el sesgo.



¿CÓMO MITIGAR ESTOS RIESGOS? AUDITA TUS DATOS, DIVERSIFICA EQUIPOS, Y MANTÉN SUPERVISIÓN HUMANA.



Tipos de sesgo en IA



Sesgo de representación

El dataset no incluye a todos los grupos por igual.

Ej: fotos solo de caras blancas para entrenar reconocimiento facial.



Sesgo histórico

Los datos reflejan injusticias pasadas.

Ej: CVs de empleados mayoritariamente hombres → IA aprende que hombres = mejor candidato.



Sesgo de algoritmo

El propio diseño del modelo favorece ciertos resultados.

Ej: función de pérdida que optimiza solo para el grupo mayoritario.



Sesgo sistémico

Desigualdades estructurales de la sociedad que se cuean en la IA.

Ej: COMPAS replicó desigualdades del sistema judicial de EEUU.




El Sesgo en la IA: Del Origen a la Solución

El Problema: ¿Por qué la IA se vuelve prejuiciosa?



Datos no representativos o incompletos

El reflejo de la "basura" informativa: Si los datos de entrada están sesgados (Garbage In), el algoritmo resultante también lo estará (Garbage Out).



Entrenamiento

Sesgo Histórico y de Selección: Los modelos suelen aprender desigualdades del pasado o se entrenan con muestras que no representan la realidad total.



Despliegue



Falta de supervisión humana ante resultados discriminatorios en vivo.



Estereotipos en la automatización

Modelos de imágenes o traducción que asocian erróneamente profesiones específicas con géneros o etnias particulares.

La Solución: Estrategias para una IA Justa



Datos y Equipos Diversificados

Diversificación de equipos y datos: Incluir voces diversas en el desarrollo para identificar sesgos que los algoritmos no ven.



Monitoreo Continuo

Monitoreo y Auditorías Continuas: Evaluar el modelo tras su despliegue para detectar sesgos emergentes en entornos reales.



Gobernanza

Gobernanza de la IA: Implementar políticas y marcos de transparencia para guiar un desarrollo tecnológico ético y responsable.

Etapas del Ciclo y Riesgo Principal

Etapas del Ciclo	Riesgo Principal
Recolección de Datos	Datos no representativos o incompletos de la población real.
Entrenamiento	Algoritmos que optimizan patrones basados en prejuicios históricos.
Despliegue	Falta de supervisión humana ante resultados discriminatorios en vivo.

EL LADO OCULTO DE LOS ALGORITMOS: ENTENDIENDO EL SESGO EN LA IA

Garbage in, garbage out: Si los datos de entrada están viciados, el resultado también lo estará.

¿QUÉ ES EL SESGO EN LA IA?

Resultados Distorsionados:
Aporieión de resultados sesgados debido a prejuicios humanos que contaminan los datos de entrenamiento o el diseño del algoritmo.

Una Fotografía de Nuestras Decisiones:
Los datos reflejan patrones históricos de desigualdad y las limitaciones cognitivas de quienes crean la tecnología.

EL CICLO DEL SESGO (¿DÓNDE OCURRE?)

1. Recolección de Datos
El sesgo nace aquí si los datos no son diversos o no representan la realidad total de la población.

2. Etiquetado y Entrenamiento
Los humanos que clasifican los datos pueden aplicar criterios subjetivos, y los modelos pueden "sobreajustarse" a patrones erróneos.

3. Despliegue y Monitoreo
Incluso un modelo "limpio" puede generar discriminación si no se prueba con entradas del mundo real o si carece de supervisión tras su lanzamiento.

TIPOS COMUNES DE SESGO

Sesgo Histórico vs. Selección
HISTÓRICO: Refleja prejuicios del pasado (ocurre la cuando) los datos omiten grupos específicos por comodidad

Sesgo de Estereotipos
Cuando la IA retunza clicios, como asociar automáticamente "enfermera" con el género femenino o "médico" con el masculino.

Sesgo de Confirmación
La tendencia de los analistas a huecar patrones que validan sus propias creencias preesistentes al entrenar el modelo.

RIESGOS EN EL MUNDO REAL



Discriminación en Contrataciones
Algoritmos de filtrado de currículums han llegado a poner a riesgo por hoarar en datos históricos de empresas dominadas por hombres.



Errores en Diagnósticos Médicos
Algunos sistemas de diagnóstico tienen menor precisión con pacientes afroamericanos delado e la falta de diversidad en los datos de entrenamiento.



Vigilancia Policial Predictiva
El uso de datos históricos de arrestos puede coluara porhlos restotar y etecar desproporcionadamente a comunidades minoritarias.

ESTRATEGIAS DE MITIGACIÓN



Equipos Diversos e Inclusivos
Contar con grupos multidiscipliastios y variados en gónaro y otala apado a identificar esagas que un equipo homogéneo pssería por alto.



El Factor "Human-in-the-Loop"
Establecer sistemas donde las recomendaciones de la IA ceaa vealiadas y aprohadas por decisiones humanas fiostes.



Gobernanza y Auditoría de IA
Implementar políticas de transparencia y auditorías esternas para evatoar la oquidad de los modelos de forma continuo.



Grupo V: ¿Cómo podemos evitarlos?



Guía para una IA Ética: Ruta Crítica Contra el Sesgo

Un proceso de cuatro etapas para construir modelos de IA justos y precisos, combatiendo el sesgo en la selección de datos, la configuración algorítmica y la auditoría humana continua.

FASE DE CREACIÓN: Datos y Algoritmos

● Diversidad y Balanceo de Datos

Garantiza representación equitativa y usa técnicas como SMOTE para visibilizar minorías.

● Eliminación de "Proxies"

Detecta variables que deducen indirectamente datos sensibles como género o etnia.

● Algoritmos con Ética

Configura funciones de pérdida que penalicen activamente cualquier decisión discriminatoria.

FASE DE CONTROL: Evaluación y Gobierno

● La Trampa del "Accuracy"

Un modelo preciso globalmente puede fallar sistemáticamente con grupos específicos.

● Análisis por Segmentos

Desglosa los resultados por subgrupos en lugar de mirar solo promedios generales.

Precisión Global: 95%

Subgrupo A: 0%



● IA Explicable (XAI) y Diversidad

Usa herramientas como SHAP y equipos multidisciplinarios para evitar puntos ciegos.



Comparación: Enfoque Tradicional vs. Equidad




ENFOQUE TRADICIONAL

- **Precisión Global (Accuracy):** Puede ser 99% preciso pero fallar 100% en minorías.




ENFOQUE BASADO EN EQUITAD

- **Métricas de Equidad:** Evalúa el impacto dispar y garantiza igualdad de oportunidades.
- **Equipos Diversos:** Aportan perspectivas de ética, leyes y negocio para reducir sesgos.



¿Cómo evitar los sesgos en un modelo y en el análisis de datos?



Buenas prácticas para reducir sesgos en todo el ciclo de vida del modelo

1 Antes de entrenar: revisar los datos



- Comprobar que los datos sean representativos.
- Revisar el balance de clases.
- Identificar variables sensibles: género, edad, origen, ubicación, nivel socioeconómico, discapacidad.
- Detectar datos históricos sesgados.
- Verificar que las etiquetas estén bien definidas.

Ejemplo: si un histórico de contratación favoreció a hombres, el modelo puede aprender ese patrón injusto.

2 Durante el análisis de datos



- No mirar solo métricas globales.
- Analizar resultados por subgrupos.
- Comparar tasas de error entre grupos.
- Detectar outliers y patrones sospechosos.
- Revisar correlaciones indirectas y variables proxy.
- Documentar supuestos, decisiones y limitaciones.

Pregunta clave: ¿El modelo funciona igual de bien para todos los grupos?

3 Durante el entrenamiento del modelo



- Re-muestreo para balancear grupos.
- Reponderación de ejemplos minoritarios.
- Eliminar o transformar variables problemáticas.
- Usar restricciones de equidad cuando sea posible.
- Aplicar validación cruzada estratificada.

Importante: quitar una variable sensible no siempre elimina el sesgo, porque otras variables pueden actuar como proxies.

4 En la evaluación



- Medir accuracy, precision, recall y F1.
- Evaluar errores por grupo.
- Comparar false positivos y false negativos por grupo.
- Revisar métricas de equidad: demographic parity, equal opportunity y equalized odds.

No basta con una buena métrica global; hay que medir el impacto en cada grupo.

5 Revisión humana y auditoría



- Incluir expertos del dominio.
- Consultar perfiles de legal, ética o compliance.
- Escuchar a usuarios afectados.
- Realizar auditorías internas o externas.
- Revisar casos límite.
- Documentar con datasheets y model cards.

6 Después del despliegue



- Monitorizar cambios en los datos.
- Vigilar rendimiento por subgrupo.
- Detectar drift del modelo y de los datos.
- Recoger feedback y quejas de usuarios.
- Corregir errores y reentrenar cuando sea necesario.



Idea clave

El sesgo no se corrige una sola vez. Debe controlarse de forma continua: en los datos, el entrenamiento, la evaluación y el uso real del modelo.

Resumen rápido



¿Qué podemos hacer al respecto?

01



Auditar los datos

Revisar los datasets buscando desequilibrios: ¿hay grupos infrarrepresentados? ¿Los datos reflejan injusticias pasadas?

02



Medir el sesgo

Evaluar el modelo por grupos: ¿funciona igual de bien para hombres que para mujeres? ¿Para distintas etnias?

03



Diversidad en equipos

Un equipo diverso detecta antes los puntos ciegos. Si todos los ingenieros son iguales, nadie ve los problemas.

04



IA explicable

Exigir transparencia: si un algoritmo toma decisiones sobre personas, las personas deben poder entenderlas y cuestionarlas.





Grupo VI: Tríada CID



Seguridad y Tríada CID

Estrategias de la Tríada CID

Los tres pilares fundamentales para proteger la información empresarial.



¿Qué es la Tríada CID?

Un modelo fundamental diseñado internacionalmente para guiar y estructurar las políticas de ciberseguridad y gobernanza de la información en cualquier organización moderna.



El Objetivo Fundamental

Alcanzar un equilibrio perfecto entre la accesibilidad ágil a los datos y su protección estricta ante amenazas internas y externas.



La Regla de Oro

Los tres pilares son interdependientes. Si uno solo de estos principios se ve comprometido, toda la estructura de seguridad de la infraestructura se desploma.





La IA que construyamos será el espejo de nuestra sociedad.

Depende de nosotros decidir qué imagen queremos que refleje.



Los sesgos vienen de los datos y del mundo real



Pueden tener consecuencias graves en vidas reales



Existen herramientas para detectarlos y reducirlos





Somos
F5

ABRIMOS RUTAS **INCLUSIVAS**
AL TALENTO DIGITAL