



Somos
F5

El punto ciego

Auditoría de algoritmos y variables proxy

ABRIMOS RUTAS INCLUSIVAS
AL TALENTO DIGITAL

Hoja de ruta

Bloque I: Repaso express

- El reflejo de la historia (Caso Amazon)
- El sesgo de representación (Gender Shades)
- La paradoja matemática (COMPAS)

Bloque II: El punto ciego

- Variables protegidas frente a variables proxy
- La ilusión de la “ceguera algorítmica” (Fairness through blindness)

Bloque III: Laboratorio

- Contexto del dataset anonimizado
- Objetivo de la auditoría adversarial



Repaso express: El espejo de los datos

Sesgos de Origen y Representación

1. Sesgo Histórico (Caso Amazon, 2015)

- ¿Qué se pretendía lograr?
- ¿Qué problema se dio en los datos?
- ¿Y qué sucedió como resultado?

2. Sesgo de Representación (Gender Shades, 2018)

- ¿Qué se pretendía lograr?
- ¿Qué problema se dio en los datos?
- ¿Y qué sucedió como resultado?



Repaso express: El espejo de los datos

Sesgos de Origen y Representación

1. Sesgo Histórico (Caso Amazon, 2015)

- **El objetivo:** Algoritmo de cribado de currículums para perfiles técnicos.
- **El problema:** Datos de entrenamiento basados en contrataciones de los 10 años anteriores (predominantemente masculinas).
- **El resultado:** El modelo penalizó activamente la palabra "mujeres" (ej. "club de ajedrez de mujeres") y priorizó verbos de acción agresivos asociados culturalmente a perfiles masculinos.

2. Sesgo de Representación (Gender Shades, 2018)

- **El objetivo:** Sistemas comerciales de reconocimiento facial con alta tasa de error.
- **El problema:** Datasets de entrenamiento subrepresentados (mayoría de rostros masculinos y de piel clara).
- **El resultado:** Brecha de precisión extrema. Error menor al 1% en hombres de piel clara frente a errores de hasta el 34.7% en mujeres de piel oscura.



Repaso express: El teorema de la imposibilidad

● El Caso COMPAS (ProPublica, 2016)

Algoritmo de predicción de reincidencia criminal en EE.UU.

- **Paridad predictiva:** El sistema era igual de preciso para predecir el riesgo general tanto en personas blancas como afroamericanas.
- **Desigualdad en la tasa de error:** El sistema cometía errores asimétricos:
 - **Falsos Positivos:** Clasificaba al doble de personas afroamericanas como "de alto riesgo" cuando en realidad no reincidían.
 - **Falsos Negativos:** Clasificaba al doble de personas blancas como "de bajo riesgo" cuando en realidad sí reincidían.



Hoja de ruta

Bloque I: Repaso express

- El reflejo de la historia (Caso Amazon)
- El sesgo de representación (Gender Shades)
- La paradoja matemática (COMPAS)

Bloque II: El punto ciego

- Variables protegidas frente a variables proxy
- La ilusión de la “ceguera algorítmica” (Fairness through blindness)

Bloque III: Laboratorio

- Contexto del dataset anonimizado
- Objetivo de la auditoría adversarial



El Mito de la Ceguera Algorítmica

La Falacia del "Fairness through Blindness"

- **La práctica común:** Pensar que al eliminar columnas sensibles (género, etnia, edad), el modelo se vuelve mágicamente inmune a discriminar.
- **La realidad del Machine Learning:** Los algoritmos de alta dimensionalidad no necesitan ver la variable protegida original si existen **Variables Proxy** en el dataset.



El punto ciego

Variable protegida vs. Variable proxy

- **Variable protegida:** Atributo demográfico o personal legalmente protegido contra la discriminación (género, etnia, orientación sexual, edad).
- **Variable proxy:** Una variable aparentemente neutral y legítima que está altamente correlacionada con una variable protegida.

El mito del "Fairness through Blindness"

Eliminar la columna de la variable protegida **no elimina el sesgo**. Los modelos de Machine Learning de alta dimensionalidad detectan la redundancia y reconstruyen la variable protegida usando los proxies.



Hoja de ruta

Bloque I: Repaso express

- El reflejo de la historia (Caso Amazon)
- El sesgo de representación (Gender Shades)
- La paradoja matemática (COMPAS)

Bloque II: El punto ciego

- Variables protegidas frente a variables proxy
- La ilusión de la “ceguera algorítmica” (Fairness through blindness)

Bloque III: Laboratorio

- Contexto del dataset anonimizado
- Objetivo de la auditoría adversarial



Laboratorio: Contexto (Blind Test)

El Escenario

Un modelo predictivo de concesión de microcréditos financieros ha sido entrenado omitiendo las variables de género y origen socioeconómico de los solicitantes para cumplir con la normativa.

El dataset

- Datos: 800 registros reales extraídos de producción financiera.
- Variables de Entrada: Feature_1 (categórica), Feature_2 (métrica continua de aptitud), Feature_3 (binaria estructural).
- Variable de Salida: Target (1 = Aprobado, 0 = Denegado).

Vuestra Misión

Debéis calcular la tasa de aprobación de préstamos para cada grupo de la variable Feature_1 (Alpha, Beta, Gamma) y compararla con el rendimiento técnico de Feature_2.

