



Somos
F5

Introducción al Machine Learning:

Paradigmas de aprendizaje

ABRIMOS RUTAS **INCLUSIVAS**
AL TALENTO DIGITAL

Hoja de ruta


Bloque I: El ecosistema de la IA (15 min)	• Definición de IA, Machine Learning y Deep Learning • IA Débil vs. IA Fuerte • Cambio de paradigma informático
Bloque II: El Aprendizaje Supervisado (30 min)	• Estructura de entradas, salidas y el concepto de etiqueta • Clasificación vs. Regresión • Casos reales y el coste del etiquetado
Bloque III: El Aprendizaje No Supervisado (30 min)	• Descubrimiento de patrones sin guía • Clusterización y reducción de dimensiones • Estructuras conceptuales y espacios latentes
Bloque IV: Anatomía de un modelo (15 min)	• Datos, parámetros y funciones de error • El proceso de optimización y entrenamiento



El mapa conceptual de la IA

Desmitificando conceptos y delimitando fronteras

- **Inteligencia Artificial (IA)**
 - **Machine Learning (ML)**
 - **Deep Learning (DL)**
 - **Big Data**
1. ¿Cuáles son las diferencias entre estas disciplinas?
¿Cómo se relacionan?
 2. Si las bases matemáticas de las redes neuronales ya existían en los 80, ¿por qué crees que el Deep Learning ha explotado en la última década?



El cambio de paradigma informativo

Programación clásica vs. Aprendizaje automático

Componente	Programación Clásica	Machine Learning
Entradas del sistema	Datos de origen + Reglas lógicas lógicas escritas a mano	Datos de origen + Respuestas/Experiencias conocidas
Procesamiento	El ordenador ejecuta de forma secuencial las reglas lógicas fijas.	El algoritmo busca patrones analíticos y correlaciones óptimas.
Salida del sistema	Respuestas finales calculadas a partir de las reglas.	Un modelo de conocimiento (Reglas lógicas automatizadas).



Debate

¿Cuándo programar y cuándo dejar que el sistema aprenda?

- **Enunciado:** Analiza los siguientes tres escenarios de software. Determina razonadamente si se deben abordar mediante **Programación Clásica** o mediante **Machine Learning**:
 1. Un sistema bancario que calcula el IVA de una factura comercial.
 2. Un filtro de correo que detecta si un email entrante es fraudulento o legítimo.
 3. El sistema de control de un ascensor residencial que responde a las pulsaciones de los botones de los pisos.



Qué es el Machine Learning

La generalización del conocimiento a partir de la experiencia

- **Principio básico:** Extraer conclusiones generales a partir de experiencias particulares acumuladas.
- **El aprendizaje:** Un sistema computacional aprende si es capaz de mejorar su rendimiento en una tarea específica a medida que se le exponen más datos e información de entrenamiento.
- **La meta: Generalización.**
 - No nos interesa que el algoritmo memorice los datos del pasado.
 - El éxito real radica en su capacidad para ofrecer respuestas correctas ante datos completamente nuevos e inéditos que jamás ha visto durante su entrenamiento.



Hoja de ruta

Bloque I: El ecosistema de la IA (15 min)	• Definición de IA, Machine Learning y Deep Learning • IA Débil vs. IA Fuerte • Cambio de paradigma informático
Bloque II: El Aprendizaje Supervisado (30 min)	• Estructura de entradas, salidas y el concepto de etiqueta • Clasificación vs. Regresión • Casos reales y el coste del etiquetado
Bloque III: El Aprendizaje No Supervisado (30 min)	• Descubrimiento de patrones sin guía • Clusterización y reducción de dimensiones • Estructuras conceptuales y espacios latentes
Bloque IV: Anatomía de un modelo (15 min)	• Datos, parámetros y funciones de error • El proceso de optimización y entrenamiento



Aprendizaje supervisado

El paradigma de las entradas, las salidas y las etiquetas

- **Mecanismo:** El algoritmo se entrena utilizando un conjunto de datos histórico donde cada muestra contiene tanto las variables de entrada (características o *features*) como su resultado correcto asociado (variable de salida, objetivo o **etiqueta**).
- **El rol del supervisor:** El término "supervisado" proviene del hecho de que al proporcionar la respuesta correcta al algoritmo, estamos guiando y supervisando matemáticamente su proceso de ajuste.
- **Objetivo final:** Descubrir la función matemática oculta que mapea de forma óptima las entradas con las salidas, permitiendo predecir la etiqueta de nuevas entradas en el futuro.



Intuición matemática del aprendizaje supervisado

Ejemplo práctico de inducción de reglas por observación

- Analiza la siguiente secuencia de experiencias proporcionada a un algoritmo:
 - **Entrada (x):1 → Salida (y):2**
 - **Entrada (x):2 → Salida (y):4**
 - **Entrada (x):6 → Salida (y):12**
 - **Entrada (x):9 → Salida (y):18**
- Si introducimos un valor de entrada inédito **x = 10**, ¿cuál es la salida esperada?




Taxonomía del aprendizaje supervisado

Clasificación vs. Regresión

- **Clasificación (Variable de salida categórica / discreta):**
 - La meta es asignar cada muestra de entrada a una categoría o clase binaria o multinomial.
 - Ejemplos: Determinar si un correo es *Spam* o *No Spam*; clasificar una imagen médica como *Benigna* o *Maligna*.
- **Regresión (Variable de salida numérica / continua):**
 - La meta es predecir un valor numérico real de rango infinito continuo.
 - Ejemplos: Predecir el precio de venta de una vivienda basándose en sus metros cuadrados; estimar la temperatura atmosférica de mañana.



Investigación: casos de estudio reales



Actividad Práctica (15 min)

Simulación de diseño de sistemas supervisados y vigilancia ética

- **Formato:** Trabajo por parejas en documento colaborativo.
- **Enunciado:** Imagina que una entidad bancaria os encarga diseñar el pipeline de datos para un modelo de Machine Learning supervisado que decida de forma automatizada si se concede o se deniega un crédito financiero.
- **Tareas a resolver:**
 1. Especificad cuáles serían vuestras variables de entrada (*features*) extraídas del cliente.
 2. Definid con precisión cuál sería vuestra variable objetivo o etiqueta de entrenamiento.
 3. **Vigilancia Ética:** Identificad al menos dos variables que, de ser incluidas en el dataset de entrada, podrían generar discriminación o sesgos algorítmicos ilícitos.



El coste oculto del Aprendizaje supervisado

La dependencia crítica del etiquetado de datos humano

- El Machine Learning supervisado es sumamente eficaz, pero adolece de un cuello de botella logístico: **necesita millones de etiquetas correctas.**
- **El coste del etiquetado:**
 - Para entrenar un modelo de visión artificial que distinga especies animales, un equipo de humanos debe revisar individualmente miles de imágenes marcando la solución.
 - Datasets estándar de la industria requieren con frecuencia etiquetar manualmente más de 100.000 ejemplos para alcanzar precisiones aceptables en entornos productivos.
- Esto genera un elevado coste financiero y temporal antes de poder escribir la primera línea de entrenamiento de un modelo.



Hoja de ruta

Bloque I: El ecosistema de la IA (15 min)	• Definición de IA, Machine Learning y Deep Learning • IA Débil vs. IA Fuerte • Cambio de paradigma informático
Bloque II: El Aprendizaje Supervisado (30 min)	• Estructura de entradas, salidas y el concepto de etiqueta • Clasificación vs. Regresión • Casos reales y el coste del etiquetado
Bloque III: El Aprendizaje No Supervisado (30 min)	• Descubrimiento de patrones sin guía • Clusterización y reducción de dimensiones • Estructuras conceptuales y espacios latentes
Bloque IV: Anatomía de un modelo (15 min)	• Datos, parámetros y funciones de error • El proceso de optimización y entrenamiento




Aprendizaje no supervisado

Producción de conocimiento sin guías ni etiquetas previas

- **Mecanismo:** El algoritmo recibe única y exclusivamente variables de entrada (datos sin etiquetar). No existe ninguna variable de salida objetivo ni un supervisor humano que indique cuál es la respuesta correcta.
- **Objetivo fundamental:** Analizar la topología y geometría de los datos para descubrir de forma autónoma estructuras internas latentes, patrones de similitud, agrupamientos naturales o anomalías ocultas.
- **Valor de futuro:** La comunidad científica global coincide en que el futuro de la Inteligencia Artificial Avanzada reside en este paradigma, ya que elimina por completo la dependencia del coste humano de etiquetado de datos.




Clusterización: el arte de agrupar




Si te dijera que aquí hay símbolos de diversos lenguajes, ¿cómo los agruparías?



Clusterización: el arte de agrupar



Clusterización: el arte de agrupar



El espacio latente

Cómo las máquinas construyen mapas de conceptos abstractos

- Un **espacio latente** es una representación matemática abstracta de dimensiones reducidas donde el algoritmo organiza los datos según sus características conceptuales internas subyacentes.
- **Ejemplo:**
 - ¿Cómo definimos matemáticamente una silla si existen de cuatro patas, de oficina con ruedas, taburetes, mecedoras o sofás de diseño?
 - Los algoritmos no supervisados analizan miles de objetos e infieren la estructura conceptual oculta de la "silla" en un espacio latente.
- Una vez construido este espacio, el modelo puede medir con precisión matemática si un objeto es conceptualmente similar a otro o calcular distancias semánticas entre palabras o imágenes.



Actividad de lógica (10 min)

● Cartografía mental y diseño conceptual de un Espacio Latente Semántico

- Imagina un espacio latente bidimensional (eje X y eje Y) diseñado para organizar conceptos del reino animal.
- Determina qué concepto abstracto o propiedad física debería gobernar el **eje X** y cuál el **eje Y** para que los siguientes cuatro animales queden perfectamente ordenados y separados en los cuatro cuadrantes del plano cartesiano:
 - *Águila real*
 - *Tiburón blanco*
 - *Avestruz*
 - *Delfín mular*



Resumen comparativo de los paradigmas

Criterio Técnico	Aprendizaje Supervisado	Aprendizaje No Supervisado
¿Requiere etiquetas de salida?	Sí de forma obligatoria.	No, opera solo con variables de entrada.
Objetivo Algorítmico	Mapear entradas con salidas para realizar predicciones precisas.	Descubrir la estructura interna oculta y agrupamientos de los datos.
Tareas Principales	Clasificación y Regresión.	Clusterización y Reducción de Dimensionalidad.
Coste de Obtención de Datos	Elevado debido al proceso humano de etiquetado.	Bajo, consume datos brutos no estructurados.





Hoja de ruta

Bloque I: El ecosistema de la IA (15 min)	• Definición de IA, Machine Learning y Deep Learning • IA Débil vs. IA Fuerte • Cambio de paradigma informático
Bloque II: El Aprendizaje Supervisado (30 min)	• Estructura de entradas, salidas y el concepto de etiqueta • Clasificación vs. Regresión • Casos reales y el coste del etiquetado
Bloque III: El Aprendizaje No Supervisado (30 min)	• Descubrimiento de patrones sin guía • Clusterización y reducción de dimensiones • Estructuras conceptuales y espacios latentes
Bloque IV: Anatomía de un modelo (15 min)	• Datos, parámetros y funciones de error • El proceso de optimización y entrenamiento



Anatomía de un modelo




El dilema del modelado

El frágil equilibrio entre la aproximación analítica y la simplicidad

- Un modelo de Machine Learning busca constantemente el equilibrio óptimo entre dos fuerzas contrapuestas:
 1. **Máxima Aproximación:** Capacidad de ajustarse fielmente a los datos reales observados.
 2. **Máxima Simplicidad:** Mantener una estructura matemática gestionable, interpretable y capaz de generalizar ante datos futuros.
- **El riesgo:** Si intentamos diseñar un modelo que recoja todas las excepciones y anomalías de la realidad, acabaremos con un sistema masivo e inmanejable.
- **La solución:** El uso estratégico de la **probabilidad**.



Caso histórico



Los tres pilares del ML

Los componentes indispensables de todo algoritmo de aprendizaje

Todo sistema de Machine Learning se compone de la interacción sistemática de **tres pilares** fundamentales:

1. **Los Datos:** Nuestra toma de contacto empírica con la realidad. Mediciones históricas estructuradas y multidimensionales de las variables del sistema.
2. **Los Parámetros:** Los valores numéricos internos del algoritmo que aportan flexibilidad al modelo y que pueden ser modificados dinámicamente para alterar su comportamiento y forma matemática.
3. **La Función de Error (o de Pérdida):** La métrica matemática encargada de evaluar la distancia analítica exacta entre las predicciones teóricas de nuestro modelo y las evidencias reales de los datos.





**Somos
F5**

www.somosf5.org

Síguenos en

