

Hoja de ruta del día

- **Módulo:** Módulo III: Machine Learning
- **Sesión:** Semana 14, Fase 1: Preprocesamiento (feature engineering)
- **Temática Central:** Limpieza avanzada para ML: Imputación de nulos (SimpleImputer vs KNNImputer) y detección de duplicados.
- **Stack Requerido:** Python, Scikit-Learn, Pandas

Objetivos de aprendizaje del día

Al finalizar la jornada de investigación autónoma, debes ser capaz de:

- **Objetivo 1:** Comprender e implementar la lógica matemática y algorítmica detrás de la imputación estadística básica ([SimpleImputer](#)) frente a la imputación basada en vecindad ([KNNImputer](#)), identificando las ventajas y limitaciones computacionales de cada una.
- **Objetivo 2:** Detectar y gestionar registros duplicados en conjuntos de datos complejos, diferenciando entre duplicidad exacta y duplicidad parcial basada en subconjuntos de características críticas.
- **Objetivo 3:** Evaluar críticamente el impacto de la imputación en la distribución original de los datos para evitar la introducción de sesgos artificiales o fenómenos de fuga de datos (*data leakage*).

Bibliografía

Aquí tienes los recursos de referencia para solucionar el reto técnico (no dudes en ampliar la investigación con otras fuentes):

- **Documentación Oficial 1:** [Scikit-Learn API: SimpleImputer documentation](#)
- **Documentación Oficial 2:** [Scikit-Learn API: KNNImputer documentation](#)
- **Documentación Oficial 3:** [Pandas API: DataFrame.duplicated documentation](#)

Ejemplo de implementación práctica

Consulta el notebook del día.

Reto práctico de código

Contexto del problema

Una entidad financiera está desarrollando un modelo predictivo para evaluar el riesgo crediticio de sus solicitantes. El conjunto de datos crudo contiene registros históricos con variables críticas como `Edad`, `Ingresos_Anuales` y `Puntuacion_Credito`. Debido a problemas en la migración de sistemas y fallos en los formularios de captura de la web, el dataset presenta un alto volumen de registros faltantes y se sospecha la presencia de filas duplicadas causadas por reintentos de envío de los usuarios.

Componente de incertidumbre

Te enfrentas a un dataset donde la estrategia de imputación simple (como rellenar con la media) puede distorsionar gravemente la varianza de la columna `Ingresos_Anuales`. Deberás investigar de forma autónoma cómo configurar `KNNImputer` ajustando adecuadamente el parámetro de vecinos más cercanos (`n_neighbors`) y evaluar mediante métricas estadísticas descriptivas (desviación estándar y media antes/después) cuál de las dos estrategias preserva mejor la naturaleza de la distribución de los datos originales. Además, deberás tratar duplicados considerando situaciones donde no existe un ID único.

Restricción ética y responsabilidad

La imputación automatizada en modelos de concesión de créditos puede amplificar la exclusión financiera si no se supervisa. Si los valores faltantes pertenecen mayoritariamente a un sector demográfico específico (por ejemplo, personas jóvenes con ingresos variables), imputar a ciegas valores erróneos podría catalogarlos incorrectamente como perfiles de alto riesgo o viceversa. Deberás **justificar mediante un breve análisis escrito** cómo el método elegido minimiza el riesgo de penalización injusta basándose en la conservación de las distribuciones por subgrupos.