



Somos
F5

Aprendizaje supervisado I: Introducción a la regresión lineal y logística

**ABRIMOS RUTAS INCLUSIVAS
AL TALENTO DIGITAL**

Hoja de ruta

Bloque I:
**Fundamentos de la regresión
lineal**
(30 min)

- Ecuación matemática, mínimos cuadrados ordinarios y optimización
- Evaluación de modelos de regresión lineal

Bloque II:
**Fundamentos de la regresión
logística**
(30 min)

- Clasificación binaria, función sigmoide y función de coste
- Evaluación de modelos de regresión logística



Dilema

Planteamiento:

Formáis parte del equipo de IA de un hospital público. Debéis desplegar un modelo para predecir el riesgo de reingreso en UCI. Disponéis de una **regresión logística** con un **78% de precisión** cuyas variables son totalmente comprensibles por el equipo médico, y de una **red neuronal profunda** con un **83% de precisión** pero indescifrable.

Debate:

¿Qué modelo proponéis desplegar en producción y qué argumentos técnicos y éticos defenderíais ante la dirección del hospital?



Hoja de ruta

Bloque I:
**Fundamentos de la regresión
lineal**
(30 min)

- Ecuación matemática, mínimos cuadrados ordinarios y optimización
- Evaluación de modelos de regresión lineal

Bloque II:
**Fundamentos de la regresión
logística**
(30 min)

- Clasificación binaria, función sigmoide y función de coste
- Evaluación de modelos de regresión logística



Regresión lineal: fundamentos teóricos

Hipótesis del modelo


- Asume una relación lineal entre las variables independientes (características) y la variable dependiente continua y .

Formulación matemática para n características

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \epsilon$$

Componentes de la ecuación

- β_0 : Intercepto o sesgo (valor esperado de y cuando todas las x son cero).
- β_i : Coeficientes o pesos numéricos asignados a cada característica x_i .
- ϵ : Término de error aleatorio o residuo (ruido no medido).



Notación matricial

$$\hat{y} = \mathbf{X}\beta$$



El método de mínimos cuadrados ordinarios

¿Cómo medimos el error del modelo?


El objetivo es encontrar los parámetros óptimos de los coeficientes que minimicen las desviaciones de las predicciones.

Función de coste del error cuadrático medio (MSE)


$$J(\beta) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2 = \frac{1}{m} \|y - \mathbf{X}\beta\|^2$$

¿Por qué elevamos los errores al cuadrado?

- Elimina los signos negativos.
- Penaliza outliers.



¿Cómo hallamos la mejor línea?



1. La ecuación normal

Resolución analítica

- Obtiene la solución exacta en un solo paso mediante álgebra lineal

La ecuación normal



$$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y$$

El coste de la inversión matricial


- Para realizar el cálculo se requiere invertir una matriz de tamaño $n * n$ (donde n es el número de características).
- Alta complejidad computacional.



2. El descenso del gradiente



2. El descenso del gradiente



Investigación: métricas de regresión lineal

- **Formato:** Trabajo en equipos (3 grupos)
- **Tiempo:** 10 minutos de investigación + 5-10 minutos de puesta en común
- **Misión:** Cada equipo defenderá una métrica de regresión frente a un cliente de negocio.

Debéis resolver:

- ¿qué mide?
 - ¿cuándo es la mejor opción?
 - ¿cuál es su talón de Aquiles?
- **Distribución de retos**
 - Equipo 1: **MSE** (Error cuadrático medio) + **RMSE** (Raíz del error cuadrático medio)
 - Equipo 2: **MAE** (Error absoluto medio)
 - Equipo 3: **R^2 (Coeficiente de determinación) + R^2 ajustado**



Hoja de ruta

Bloque I:
**Fundamentos de la regresión
lineal**
(30 min)

- Ecuación matemática, mínimos cuadrados ordinarios y optimización
- Evaluación de modelos de regresión lineal

Bloque II:
**Fundamentos de la regresión
logística**
(30 min)

- Clasificación binaria y función sigmoide
- Evaluación de modelos de regresión logística




Fundamentos de la regresión logística

¿Cómo trazamos la línea en problemas de clasificación?

Objetivo: Queremos predecir una variable binaria (0 o 1), por ejemplo **Suspende** o **Aprueba**.

Los datos reales se agrupan únicamente en las franjas extremas de nuestro gráfico.




La función sigmoide

La magia de "aplastar" la línea recta

- La regresión logística utiliza la función sigmoide para transformar la recta en una curva.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$


- Mapea cualquier valor real al rango abierto (0, 1).
- Interpretación como probabilidad:** El valor obtenido en el eje Y nos dará la probabilidad de pertenecer a la clase positiva. Una salida de 0.75 significa un 75% de probabilidad de aprobar.



¿Cómo se elige la mejor curva?

Olvida la suma de residuos al cuadrado

- **La máxima verosimilitud (Maximum Likelihood):** método que busca la curva que haga que los datos reales observados sean lo más probables posible.



- El algoritmo proyecta cada punto real sobre la curva actual para medir su probabilidad.
- Si un estudiante aprobó (1) y la curva en ese punto dice 0.9, es una alta verosimilitud (buen ajuste).
- Multiplicamos (o sumamos sus logaritmos) todas las verosimilitudes individuales para obtener una puntuación global de la curva.
- El sistema rota y traslada la curva "S" iterativamente hasta encontrar la posición que maximice esa puntuación.



El umbral de decisión

Cómo convertir probabilidades en acciones

El umbral por defecto (0.5): Si la probabilidad estimada es igual o mayor al 50% (0.5), el modelo clasifica el caso como Clase 1 (Aprobado). Si es menor (< 0.5), lo clasifica como Clase 0 (Suspenso).

Imagina que el modelo controla un coche autónomo para distinguir un peatón (1) de una bolsa de plástico (0). Con una probabilidad del 40% de ser peatón y el umbral en 0.5, el coche no frenará. ¿Es seguro mantener ese umbral? ¿Hacia dónde lo moverías y qué efectos secundarios tendría?



Métricas de regresión logística

Indicadores basados en aciertos y fallos:

- **Matriz de Confusión:** Tabla que compara los aciertos del modelo. Muestra Verdaderos Positivos (VP), Verdaderos Negativos (VN), Falsos Positivos (FP) y Falsos Negativos (FN).
- **Exactitud (Accuracy):** Proporción de predicciones correctas sobre el total de casos. Puede ser engañosa si los datos están desbalanceados.
- **Precisión:** Mide cuántos de los casos etiquetados como positivos lo eran realmente.
- **Exhaustividad (Recall o Sensibilidad):** Mide cuántos casos positivos reales fueron identificados.
- **F1-Score:** Equilibrio (media armónica) entre la Precisión y la Exhaustividad.
- **Curva AUC-ROC:** Mide la capacidad del modelo para distinguir entre clases en diferentes umbrales de probabilidad. Mientras más cerca esté el área (AUC) a 1.0, mejor es el modelo.
- **Log Loss (Pérdida Logarítmica):** Mide la incertidumbre de las probabilidades predichas; cuanto más cerca a 0, mayor es la precisión del modelo



Tabla comparativa

Criterio Técnico	Regresión Lineal (OLS)	Regresión Logística
Variable Objetivo	Continua e ilimitada (e.g. Salarios, Ventas, Alturas)	Binaria y acotada (0 o 1, e.g. Fraude, Fuga de clientes)
Función de Coste	Error Cuadrático Medio (MSE)	Entropía Cruzada Binaria (Log Loss)
Solución de Parámetros	Analítica Cerrada (Ecuación Normal)	Numérica Iterativa (Solvers: L-BFGS, Newton-CG)
Escalado Previo	No obligatorio si se usa Ecuación Normal; sí para Regularización	Obligatorio por solvers numéricos y regularización estándar
Métricas Clave	R^2 Ajustado, Error Absoluto Medio (MAE), RMSE	Precision, Recall, ROC-AUC, F1-Score



Reto práctico

1. El diagnóstico en parejas (10 min)

Vais a entrenar una regresión logística simple sin escalar las variables numéricas. Analizad por qué Scikit-Learn arroja el error: `ConvergenceWarning: lbfgs failed to converge (status=1)`.

2. La solución del pipeline (10 min)

Implementad un Pipeline integrado utilizando `StandardScaler` de Scikit-Learn para homogeneizar las escalas numéricas y forzar una convergencia de gradiente óptima.

3. Ajuste de tolerancia (5 min)

Modificad deliberadamente los parámetros `max_iter` y `tol` en el constructor del modelo para observar cómo cambian los tiempos de entrenamiento y las advertencias.

4. Negocio (5 min)

Extraed los coeficientes del modelo entrenado y calculad los *Odds Ratios* transformándolos con `np.exp()` para explicarle el impacto real a un cliente comercial.





**Somos
F5**

www.somosf5.org

Síguenos en

