Datos

Primarios

Secundarios

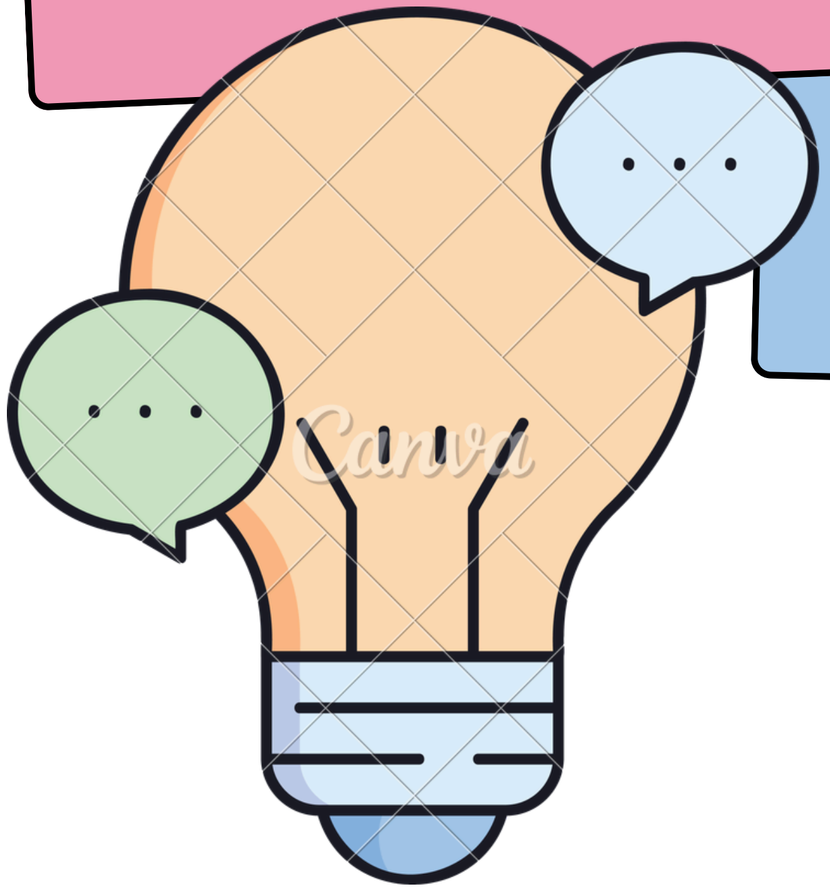

¿Qué es?

Datos Primario : Los que tomamos nosotros.

Datos Secundario : Los recoges de una fuente externa

¿Por qué es importante?

Tiene consecuencias importantes en la toma de decisiones y las responsabilidades legales.

- Toma decisiones erróneas
- Pérdida económica
- Sesgo en IA

Ejemplos reales

DATOS PRIMARIOS

1.- Datos meteorológicos recogidos por el usuario.

2.- Generación de campañas de marketing en base a los datos de los clientes propios.

3.- Encuestas de intención de voto

DATOS SECUNDARIOS

1.- Datos meteorológicos de la AEMET

2.- Generación de campañas de marketing en base a los datos del mercado

3.- Generación de datos de resultados de elecciones en base a los resultados anteriores.

Demo de código

Datos primarios

```python
import pandas as pd
import matplotlib.pyplot as plt

# Simulamos una encuesta que hicimos nosotros mismos
# (datos primarios: los generamos/recopilamos directamente)

datos_primarios = pd.DataFrame({
    'nombre':       ['Ana', 'Luis', 'María', 'Carlos', 'Sara',
                     'Pedro', 'Elena', 'Jorge', 'Lucía', 'Tomás'],
    'horas_estudio': [4, 6, 3, 7, 5, 2, 8, 4, 6, 5],
    'nivel':        ['Básico', 'Intermedio', 'Básico', 'Avanzado', 'Intermedio',
                     'Básico', 'Avanzado', 'Básico', 'Intermedio', 'Intermedio']
})

print("📊 Nuestra encuesta (datos PRIMARIOS):")
print(datos_primarios.to_string(index=False))
print(f"\n📌 Media de horas de estudio: {datos_primarios['horas_estudio'].mean():.1f} h/día")
```

```
📊 Nuestra encuesta (datos PRIMARIOS):
nombre  horas_estudio      nivel
   Ana              4     Básico
  Luis              6 Intermedio
 María              3     Básico
Carlos              7   Avanzado
  Sara              5 Intermedio
 Pedro              2     Básico
 Elena              8   Avanzado
 Jorge              4     Básico
 Lucía              6 Intermedio
 Tomás              5 Intermedio

📌 Media de horas de estudio: 5.0 h/día
```

Demo de código

Datos secundarios

```python
# Datos secundarios: extraídos de fuente pública (INE / Eurostat)
# Porcentaje de personas que usan internet a diario en España (2018-2023)

datos_secundarios = pd.DataFrame({
    'año':        [2018, 2019, 2020, 2021, 2022, 2023],
    'pct_uso_internet': [72.0, 75.5, 80.2, 83.7, 85.1, 87.4]  # % población
})

print("🌐 Uso de internet diario en España — fuente: INE (datos SECUNDARIOS):")
print(datos_secundarios.to_string(index=False))
print(f"\n📌 Incremento total 2018→2023: +{datos_secundarios['pct_uso_internet'].iloc[-1] - datos_secundarios['pct_uso_internet'].iloc[0]:.1f} puntos porcentuales")
```

```
🌐 Uso de internet diario en España — fuente: INE (datos SECUNDARIOS):
 año  pct_uso_internet
2018              72.0
2019              75.5
2020              80.2
2021              83.7
2022              85.1
2023              87.4

📌 Incremento total 2018→2023: +15.4 puntos porcentuales
```

Pregunta al grupo
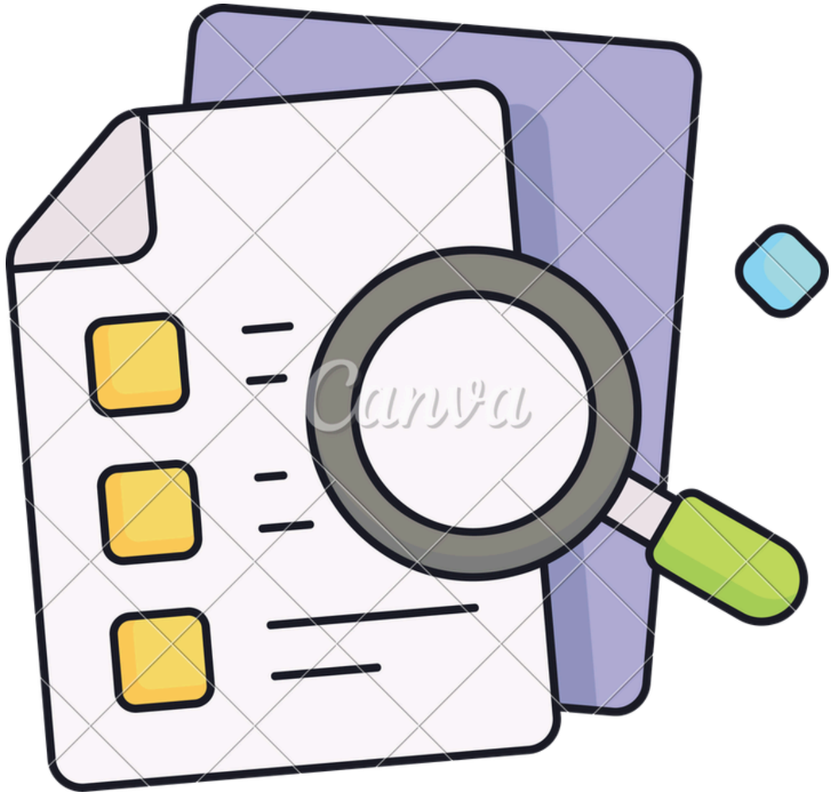
¿En qué escenarios usarías la recogida de datos primarios y secundarios?